LAPORAN
PEMBALAJARAN MESIN



Nama	: Evan Ali Prayoga Pasaribu
NIM	: 202531086
Kelas	: H-1
Nama Dosen	:Rizqia Cahyaningtyas, ST., M.Kom
No. Bangku	:4
Nama Asisten	:

1. Muhammad Ichwan Fauzi
2. Benedict Samuel Ardy

LABORATORIUM COMPUTER NETWORK
INSTITUT TEKNOLOGI PLN
2026

DAFTAR ISI

BAB I PENDAHULUAN **3**
1.1 Latar Belakang 3
1.2 Rumusan Masalah 4
1.3 Tujuan Masalah 4
1.4 Manfaat Masalah 4
BAB II LANDASAN TEORI **5**
2.1 Pembelajaran Mesin dan Alur Kerja Proyek 5
2.2 Exploratory Data Analysis (EDA) 5
2.3 Preprocessing Data 5
2.4 K-Nearest Neighbors (KNN) 6
2.5 Regresi Linear 7
2.6 Metrik Evaluasi 7
2.7 Overfitting dan Underfitting 8
BAB III PEMBAHASAN **9**
3.1 Dataset dan Lingkungan Pengerjaan 9
3.2 Import Library dan Pemuatan Data 10
3.3 Exploratory Data Analysis 11
3.4 Preprocessing Data 13
3.5 Implementasi KNN untuk Klasifikasi 14
3.6 Implementasi Regresi Linear 17
BAB IV PENUTUP **21**
4.1 Kesimpulan 21
4.2 Saran 21
DAFTAR PUSTAKA **22**

BAB I
PENDAHULUAN

1.1. Latar Belakang

Diabetes melitus merupakan salah satu masalah kesehatan global yang jumlah penderitanya terus bertambah. Menurut IDF Diabetes Atlas edisi ke-11 (International Diabetes Federation, 2025), sekitar 589 juta orang dewasa berusia 20 sampai 79 tahun hidup dengan diabetes pada tahun 2024, atau kurang lebih satu dari sembilan orang dewasa di dunia. Sekitar 252 juta di antaranya belum terdiagnosis, dan jumlah penderita diproyeksikan mencapai 853 juta pada tahun 2050. Angka tersebut menunjukkan bahwa deteksi dini menjadi kebutuhan yang mendesak, sebab diabetes tipe 2 pada tahap awal sering berjalan tanpa gejala yang jelas.

Di sisi lain, data klinis rutin seperti usia, indeks massa tubuh (BMI), riwayat hipertensi, riwayat penyakit jantung, kadar HbA1c, dan kadar glukosa darah sudah banyak tersedia di fasilitas kesehatan. Pembelajaran mesin (*machine learning*) memungkinkan komputer mempelajari pola dari data historis sehingga dapat memprediksi kondisi pasien baru tanpa diprogram dengan aturan yang ditulis satu per satu (Mitchell, 1997; Géron, 2022). Pendekatan yang memakai data berlabel ini disebut *supervised learning* dan terbagi menjadi klasifikasi untuk target kategorikal serta regresi untuk target numerik (James et al., 2021).

Pada Project UTS Pembelajaran Mesin 2026, penulis memperoleh dataset diabetes yang berisi 100.000 baris data pasien dengan sembilan kolom, serta dua algoritma yang harus dikerjakan, yaitu *K-Nearest Neighbors* (KNN) dan Regresi Linear. KNN, yang diperkenalkan oleh Cover dan Hart (1967), dipakai untuk mengklasifikasikan status diabetes pasien berdasarkan kemiripannya dengan pasien lain. Regresi Linear (Montgomery et al., 2012) dipakai untuk memodelkan target numerik, dalam hal ini kadar glukosa darah. Dua algoritma yang mewakili dua jenis tugas berbeda memberi kesempatan untuk membandingkan cara kerja, kebutuhan preprocessing, dan cara evaluasi masing-masing.

Dataset yang tersedia belum tentu langsung siap dipakai. Dataset ini memiliki baris duplikat, fitur kategorikal berupa jenis kelamin dan riwayat merokok, fitur dengan skala yang jauh berbeda, serta distribusi kelas yang timpang karena hanya sekitar 8,5 persen pasien yang berlabel diabetes. Kondisi tersebut menuntut tahap *exploratory data analysis* (EDA) dan preprocessing yang dilakukan secara sistematis (García et al., 2015; Han et al., 2012) serta pemilihan metrik evaluasi yang tidak menyesatkan (He & Garcia, 2009).

1.2. Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam laporan ini adalah sebagai berikut.

1. Bagaimana karakteristik dataset diabetes berdasarkan hasil *exploratory data analysis*?
2. Tahapan preprocessing apa yang diperlukan agar data siap dipakai oleh algoritma KNN dan Regresi Linear?
3. Seberapa baik kinerja KNN dalam mengklasifikasikan status diabetes, dan berapa nilai k yang memberikan kinerja terbaik?
4. Seberapa baik Regresi Linear memprediksi kadar glukosa darah, dan apa implikasi hasilnya terhadap kecocokan algoritma tersebut dengan data?

1.3. Tujuan Masalah

Sejalan dengan rumusan masalah, laporan ini bertujuan untuk hal-hal berikut.

1. Memahami karakteristik dataset diabetes melalui statistik deskriptif, visualisasi distribusi, dan analisis korelasi.
2. Menerapkan tahapan preprocessing yang sesuai, meliputi penghapusan duplikat, encoding fitur kategorikal, pembagian data, dan penskalaan fitur.
3. Melatih dan mengevaluasi model KNN untuk klasifikasi status diabetes serta menentukan nilai k yang paling sesuai.
4. Melatih dan mengevaluasi model Regresi Linear untuk memprediksi kadar glukosa darah, kemudian menganalisis hasilnya berdasarkan teori.

1.4. Manfaat Masalah

Bagi penulis, pengerjaan project ini melatih kemampuan menjalankan alur lengkap pembelajaran mesin, dari membaca data mentah sampai menafsirkan hasil evaluasi, dan membiasakan penulis menghubungkan angka yang keluar dari kode dengan teori yang melandasinya. Bagi pembaca atau mahasiswa lain, laporan ini dapat menjadi contoh penerapan KNN dan Regresi Linear pada data kesehatan beserta pembahasan keterbatasannya, terutama pada data dengan kelas yang tidak seimbang.

Secara praktis, hasil analisis menunjukkan bahwa akurasi saja tidak cukup untuk menilai model pada kasus deteksi penyakit. Temuan ini relevan bagi siapa pun yang ingin membangun sistem skrining berbasis data, karena kesalahan melewatkan pasien yang sebenarnya menderita diabetes berdampak lebih besar daripada kesalahan sebaliknya.

BAB II
LANDASAN TEORI

2.1 Pembelajaran Mesin dan Alur Kerja Proyek

Pembelajaran mesin adalah cabang kecerdasan buatan yang mempelajari algoritma yang kinerjanya meningkat melalui pengalaman berupa data (Mitchell, 1997). Pada *supervised learning*, setiap data latih terdiri atas fitur sebagai variabel masukan dan target sebagai variabel keluaran, lalu model belajar memetakan fitur ke target. Jika target berupa kategori, misalnya diabetes atau tidak diabetes, masalahnya disebut klasifikasi. Jika target berupa bilangan kontinu, misalnya kadar glukosa darah, masalahnya disebut regresi (James et al., 2021).

Alur kerja yang dipakai dalam laporan ini mengikuti urutan baku proyek pembelajaran mesin, yaitu pemahaman data, EDA, preprocessing, pembagian data, pelatihan model, dan evaluasi (Géron, 2022). Seluruh implementasi menggunakan bahasa Python dengan pustaka scikit-learn (Pedregosa et al., 2011).

2.2 Exploratory Data Analysis (EDA)

EDA adalah pendekatan untuk memahami data sebelum pemodelan dengan cara merangkum dan memvisualisasikannya (Tukey, 1977). Pada tahap ini peneliti memeriksa tipe data, nilai hilang, duplikasi, sebaran tiap fitur, keberadaan pencilan, keseimbangan kelas target, dan hubungan antarfitur. Statistik deskriptif memberikan gambaran ukuran pemusatan dan penyebaran, histogram memperlihatkan bentuk distribusi, sedangkan *heatmap* korelasi memperlihatkan kekuatan hubungan linear antarvariabel.

Koefisien korelasi Pearson (r) bernilai antara -1 dan 1. Nilai mendekati 1 menunjukkan hubungan linear positif yang kuat, nilai mendekati -1 menunjukkan hubungan linear negatif yang kuat, dan nilai mendekati 0 menunjukkan hubungan linear yang lemah. Perlu diingat bahwa r hanya menangkap hubungan linear, sehingga hubungan yang melengkung atau berbentuk anak tangga dapat terlihat lemah meskipun sebenarnya kuat (Han et al., 2012).

2.3 Preprocessing Data

Preprocessing bertujuan mengubah data mentah menjadi bentuk yang dapat dipelajari model dengan baik (García et al., 2015). Penghapusan baris duplikat mencegah satu pengamatan dihitung berkali-kali sehingga pengaruhnya terhadap model dan evaluasi tidak berlebihan. Fitur kategorikal perlu diubah menjadi angka karena algoritma dalam scikit-learn hanya menerima

masukan numerik. Teknik *one-hot encoding* membuat satu kolom biner untuk setiap kategori, dan opsi *drop_first* membuang satu kategori sebagai pembanding agar tidak terjadi *dummy variable trap*, yaitu multikolinearitas sempurna antarkolom dummy yang mengganggu terutama pada regresi linear.

Penskalaan fitur diperlukan oleh algoritma berbasis jarak seperti KNN. Pada standarisasi, setiap nilai diubah menjadi $z = (x - \mu) / \sigma$, dengan μ rata-rata dan σ simpangan baku fitur tersebut, sehingga setiap fitur memiliki rata-rata nol dan simpangan baku satu. Tanpa penskalaan, fitur berskala besar seperti kadar glukosa (80 sampai 300) akan mendominasi perhitungan jarak dibandingkan fitur berskala kecil seperti HbA1c (3,5 sampai 9,0) atau fitur biner.

Data kemudian dibagi menjadi data latih untuk membangun model dan data uji untuk menilai kemampuan generalisasi. Pembagian *hold-out* 80:20 yang dikombinasikan dengan *stratified sampling* menjaga proporsi kelas target tetap sama pada kedua bagian, yang penting ketika kelasnya timpang. Penskalaan harus di-*fit* hanya pada data latih, lalu diterapkan ke data uji, supaya informasi dari data uji tidak bocor ke proses pelatihan (*data leakage*) (Géron, 2022).

2.4 K-Nearest Neighbors (KNN)

KNN adalah algoritma non-parametrik berbasis instans yang sering disebut *lazy learner*, karena pada tahap pelatihan algoritma ini hanya menyimpan data latih. Saat memprediksi data baru, KNN menghitung jarak data tersebut ke seluruh data latih, mengambil k data terdekat, lalu menentukan kelas melalui suara mayoritas dari k tetangga itu (Cover & Hart, 1967). Ukuran jarak yang paling umum adalah jarak Euclidean:

$$d(x, z) = \sqrt{\left(\Sigma_j \quad (x_j \quad - z_j \quad)^2 \right)}, \; j = 1, 2, \ldots, p$$

$$\hat{y} = \text{mode} \{ y_i : x_i \in N_k \; (x) \}$$

dengan p jumlah fitur dan $N_k(x)$ himpunan k data latih yang paling dekat dengan x. Nilai k mengatur kompleksitas model. Nilai k yang kecil menghasilkan batas keputusan yang rumit dan peka terhadap *noise*, yaitu bias rendah tetapi varians tinggi sehingga rawan *overfitting*. Nilai k yang besar menghasilkan batas keputusan yang lebih halus, yaitu bias lebih tinggi tetapi varians lebih rendah (Hastie et al., 2009). Pada klasifikasi biner, k ganjil lazim dipilih untuk menghindari hasil seri.

Kelebihan KNN adalah konsepnya sederhana dan tidak mengasumsikan bentuk distribusi data. Kekurangannya ada beberapa. Algoritma ini sensitif terhadap skala fitur, biaya prediksinya besar pada data berukuran besar karena jarak dihitung ke seluruh data latih, dan kinerjanya menurun pada dimensi tinggi. Selain itu, pada data yang kelasnya timpang, tetangga terdekat

cenderung didominasi kelas mayoritas sehingga kelas minoritas sulit terdeteksi (He & Garcia, 2009).

2.5 Regresi Linear

Regresi Linear memodelkan hubungan antara satu target numerik dan sejumlah fitur dalam bentuk persamaan linear (Montgomery et al., 2012):

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p + \varepsilon$$

Parameter β diestimasi dengan metode kuadrat terkecil biasa (*ordinary least squares*, OLS) yang meminimalkan jumlah kuadrat residual, $SSE = \Sigma(y_i - \hat{y}_i)^2$. Solusi tertutupnya adalah $\hat{\beta} = (X^T X)^{-1} X^T y$. Koefisien β_j ditafsirkan sebagai perubahan rata-rata target ketika fitur x_j naik satu satuan dengan fitur lain dianggap tetap. Untuk fitur biner hasil *one-hot encoding*, koefisiennya berarti selisih rata-rata target antara kelompok bernilai 1 dan kelompok pembanding.

Model ini bertumpu pada beberapa asumsi, yaitu hubungan antara fitur dan target bersifat linear, galat saling bebas, ragam galat konstan (homoskedastisitas), galat berdistribusi normal, dan tidak ada multikolinearitas sempurna antarfitur (Montgomery et al., 2012). Apabila asumsi linearitas tidak terpenuhi, model hanya mampu menangkap sebagian kecil variasi target, dan hal ini tercermin pada nilai R^2 yang rendah. Berbeda dengan KNN, hasil prediksi OLS tidak berubah oleh penskalaan fitur, sehingga standarisasi tidak wajib dilakukan.

2.6 Metrik Evaluasi

Kinerja klasifikasi dihitung dari *confusion matrix* yang memuat empat komponen: *true positive* (TP), *true negative* (TN), *false positive* (FP), dan *false negative* (FN). Dari komponen itu diturunkan metrik pada Tabel 2.1 (Sokolova & Lapalme, 2009). Pada deteksi penyakit, kelas positif adalah pasien diabetes, sehingga FN berarti pasien yang menderita diabetes tetapi diprediksi sehat.

Tabel 2.1 Metrik evaluasi klasifikasi

Metrik	Rumus	Makna
Accuracy	(TP + TN) / (TP + TN + FP + FN)	Proporsi seluruh prediksi yang benar
Precision	TP / (TP + FP)	Dari semua prediksi positif, berapa yang benar-benar positif
Recall	TP / (TP + FN)	Dari semua data positif, berapa yang berhasil terdeteksi
F1-score	2 x Precision x Recall / (Precision + Recall)	Rata-rata harmonik precision dan recall

Akurasi dapat menyesatkan pada data tidak seimbang. Pada dataset ini, model yang selalu menebak "tidak diabetes" akan mencapai akurasi sekitar 91 persen tanpa mendeteksi satu pun pasien (Sokolova & Lapalme, 2009; He & Garcia, 2009). Karena itu *recall* dan *F1-score* pada kelas minoritas perlu diperhatikan bersama akurasi.

Untuk regresi, kesalahan prediksi diukur dengan *mean absolute error* (MAE), *mean squared error* (MSE), *root mean squared error* (RMSE), dan koefisien determinasi (R^2) seperti pada Tabel 2.2. MAE dan RMSE memiliki satuan yang sama dengan target, dan RMSE memberi bobot lebih besar pada kesalahan yang besar. R^2 menyatakan proporsi variasi target yang dijelaskan model. Nilai $R^2 = 0$ berarti model tidak lebih baik daripada selalu menebak rata-rata target (James et al., 2021).

Tabel 2.2 Metrik evaluasi regresi

Metrik	Rumus	Makna
MAE	$(1/n) \Sigma \lvert y_i - \hat{y}_i \rvert$	Rata-rata selisih mutlak prediksi terhadap nilai aktual
MSE	$(1/n) \Sigma (y_i - \hat{y}_i)^2$	Rata-rata kuadrat galat
RMSE	$\sqrt{MSE}$	Galat dalam satuan target, lebih sensitif terhadap galat besar
R^2	1 - SSres / SStot	Proporsi variasi target yang dijelaskan model

2.7 Overfitting dan Underfitting

Overfitting terjadi ketika model terlalu menyesuaikan diri dengan data latih, termasuk *noise*-nya, sehingga akurasi pada data latih tinggi tetapi pada data uji jauh lebih rendah. *Underfitting* terjadi ketika model terlalu sederhana sehingga kinerjanya rendah baik pada data latih maupun data uji (Hastie et al., 2009). Selisih antara skor latih dan skor uji menjadi indikator praktis untuk memeriksa kedua kondisi ini, dan hubungan antara kompleksitas model dan generalisasi inilah yang menjelaskan mengapa pemilihan k pada KNN penting.

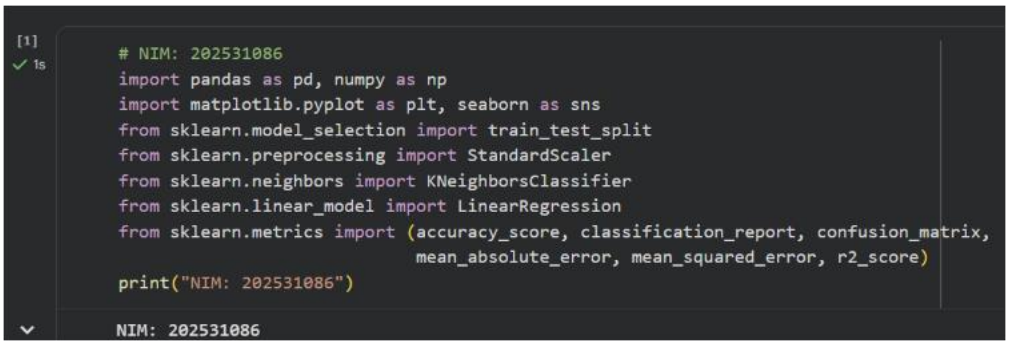
BAB III
PEMBAHASAN

3.1 Dataset dan Lingkungan Pengerjaan

Project UTS ini dikerjakan dalam platform Google Collab dengan bahasa Python-3 dan dengan data set mengenai ”Diabetes” dengan algoritma ”KNN - Regresi Linear”. dengan algoritma KNN dan Regresi Linear. Dataset berisi 100.000 baris dan sembilan kolom seperti dirangkum semua mengenai praktikan nya dibab ini.

3.2 Import Library dan Pemuatan Data

3.2.1 Cell 1: Import Library



Gambar 3.1 Cell 1 beserta output

Cell ini mengimpor seluruh pustaka yang dibutuhkan. Pandas dan numpy dipakai untuk mengolah data tabular dan perhitungan numerik, matplotlib dan seaborn untuk visualisasi. Dari scikit-learn diimpor train_test_split untuk membagi data, StandardScaler untuk standarisasi, KNeighborsClassifier dan LinearRegression sebagai dua algoritma tugas, serta fungsi metrik untuk evaluasi. Baris pertama berisi komentar NIM dan baris terakhir mencetak NIM sebagai watermark. Hasilnya, cell berjalan tanpa error dan mencetak tulisan NIM: 202531086.

3.2.2 Cell 2: Memuat Dataset

```
# NIM: 202531086
df = pd.read_csv('02_diabetes.csv')
print(df.shape)
df.info()
print("NIM: 202531086")
df.head()
```

```
(100000, 9)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 9 columns):
 #   Column               Non-Null Count   Dtype
---  ------               --------------   -----
 0   gender               100000 non-null  object
 1   age                  100000 non-null  float64
 2   hypertension         100000 non-null  int64
 3   heart_disease        100000 non-null  int64
 4   smoking_history      100000 non-null  object
 5   bmi                  100000 non-null  float64
 6   HbA1c_level          100000 non-null  float64
 7   blood_glucose_level  100000 non-null  int64
 8   diabetes             100000 non-null  int64
dtypes: float64(3), int64(4), object(2)
memory usage: 6.9+ MB
NIM: 202531086
```

	gender	age	hypertension	heart_disease	smoking_history	bmi	HbA1c_level	blood_glucose_level	diabetes
0	Female	80.0	0	1	never	25.19	6.6	140	0
1	Female	54.0	0	0	No Info	27.32	6.6	80	0
2	Male	28.0	0	0	never	27.32	5.7	158	0
3	Female	36.0	0	0	current	23.45	5.0	155	0
4	Male	76.0	1	1	current	20.14	4.8	155	0

Gambar 3.2 Cell 2 beserta output

Fungsi pd.read_csv membaca file 02_diabetes.csv ke dalam DataFrame df. Perintah df.shape menampilkan ukuran data, df.info() menampilkan nama kolom, jumlah nilai tidak null, dan tipe data, sedangkan df.head() menampilkan lima baris pertama. Hasilnya, data berukuran (100000, 9) dengan sembilan kolom yang semuanya berisi 100.000 nilai tidak null. Terdapat dua kolom bertipe object (gender dan smoking_history), tiga kolom float64, dan empat kolom int64. Dua kolom object inilah yang nantinya harus di-encode.

3.3 Exploratory Data Analysis

3.3.1 Cell 3: EDA

```
# NIM: 202531086
print(df.isnull().sum())
print("Duplikat:", df.duplicated().sum())
print(df['diabetes'].value_counts(normalize=True))
print(df.describe().T)

df.hist(figsize=(12,8)); plt.tight_layout(); plt.show()
sns.heatmap(df.select_dtypes('number').corr(), annot=True, cmap='coolwarm'); plt.show()
sns.countplot(x='diabetes', data=df); plt.show()
print("NIM: 202531086")
```

```
gender                 0
age                    0
hypertension           0
heart_disease          0
smoking_history        0
bmi                    0
HbA1c_level            0
blood_glucose_level    0
diabetes               0
dtype: int64
Duplikat: 3854
diabetes
0    0.915
1    0.085
Name: proportion, dtype: float64
                       count        mean        std   min     25%     50%  \
age                 100000.0   41.885856  22.516840  0.08   24.00   43.00
hypertension        100000.0    0.074850   0.263150  0.00    0.00    0.00
heart_disease       100000.0    0.039420   0.194593  0.00    0.00    0.00
bmi                 100000.0   27.320767   6.636783  10.01   23.63   27.32
HbA1c_level         100000.0    5.527507   1.070672   3.50    4.80    5.80
blood_glucose_level 100000.0  138.058060  40.708136  80.00  100.00  140.00
diabetes            100000.0    0.085000   0.278883   0.00    0.00    0.00

                       75%     max
age                  60.00   80.00
hypertension          0.00    1.00
heart_disease         0.00    1.00
bmi                  29.58   95.69
HbA1c_level           6.20    9.00
blood_glucose_level 159.00  300.00
```

Gambar 3.3 Cell 3: statistik, histogram, heatmap korelasi, dan distribusi kelas

Cell ini memeriksa kualitas dan karakteristik data. Perintah isnull().sum() menghitung nilai hilang per kolom, duplicated().sum() menghitung baris duplikat, dan value_counts(normalize=True) menampilkan proporsi kelas target. describe(). T menghasilkan statistik deskriptif, hist() menggambar histogram semua kolom numerik, heatmap menampilkan matriks korelasi Pearson, dan countplot menampilkan jumlah data per kelas. Hasil pemeriksaan menunjukkan tidak ada nilai hilang pada seluruh kolom, tetapi terdapat 3.854 baris duplikat dan 18 baris dengan gender Other. Kategori No Info pada smoking_history (35.816 baris) bukan nilai hilang, melainkan kategori tersendiri yang sudah terisi.

3.4 Preprocessing Data

3.4.1 Cell 4: Pembersihan dan Encoding

```
[4]
✓ 0s
    # NIM: 202531086
    df = df.drop_duplicates()
    df = df[df['gender'] != 'Other']
    df = pd.get_dummies(df, columns=['gender','smoking_history'], drop_first=True)
    print(df.shape)
    print("NIM: 202531086")

    (96128, 13)
    NIM: 202531086
```

Gambar 3.4 Cell 4 beserta output

Cell ini melakukan tiga langkah. Pertama, drop_duplicates() menghapus 3.854 baris duplikat agar tidak ada pengamatan yang terhitung berulang, yang jika dibiarkan dapat membuat skor evaluasi terlalu optimistis karena baris yang sama bisa muncul sekaligus di data latih dan data uji. Kedua, baris dengan gender Other (18 baris) dibuang karena jumlahnya terlalu sedikit untuk dipelajari model dan hanya akan menambah satu kolom dummy yang hampir selalu bernilai nol. Ketiga, get_dummies mengubah gender dan smoking_history menjadi kolom biner, dengan drop_first=True untuk menghindari dummy variable trap.

3.5 Implementasi KNN untuk Klasifikasi

3.5.1 Cell 6: Pembagian Data dan Standarisasi

```
[6]
✓ 0s
    # NIM: 202531086
    X = df.drop('diabetes', axis=1); y = df['diabetes']
    X_train, X_test, y_train, y_test = train_test_split(
        X, y, test_size=0.2, random_state=42, stratify=y)
    scaler = StandardScaler().fit(X_train)
    X_train_s, X_test_s = scaler.transform(X_train), scaler.transform(X_test)
    print(X_train.shape, X_test.shape)
    print("NIM: 202531086")

    (76902, 12) (19226, 12)
    NIM: 202531086
```

Gambar 3.5 Cell 6 beserta output

Fitur X berisi seluruh kolom kecuali diabetes, sedangkan target y adalah kolom diabetes. Fungsi train_test_split membagi data dengan perbandingan 80:20, random_state=42 agar hasilnya dapat direproduksi, dan stratify=y agar proporsi kelas pada data latih dan data uji sama. StandardScaler di-fit hanya pada data latih, kemudian transform diterapkan pada data latih dan data uji, sesuai prinsip pencegahan data leakage. Hasilnya, data latih berukuran (76902, 12) dan data uji (19226, 12), dengan 12 fitur. Data latih berisi 70.116 baris kelas 0 dan 6.786 baris kelas 1, sedangkan data uji berisi 17.530 dan 1.696 baris.

3.5.2 Cell 7: Pemilihan Nilai k

```
[7]
✓ 3m
# NIM: 202531086
for k in [3,5,7,9,11]:
    m = KNeighborsClassifier(n_neighbors=k).fit(X_train_s, y_train)
    print(k, "train:", round(m.score(X_train_s,y_train),4), "test:", round(m.score(X_test_s,y_test),4))
print("NIM: 202531086")

3 train: 0.9733 test: 0.9565
5 train: 0.9684 test: 0.9582
7 train: 0.9662 test: 0.9589
9 train: 0.9644 test: 0.9595
11 train: 0.9636 test: 0.959
NIM: 202531086
```

Gambar 3.6 Cell 7 beserta output

Perulangan for melatih model KNN untuk lima nilai k (3, 5, 7, 9, 11), kemudian mencetak akurasi pada data latih dan data uji lewat m.score.

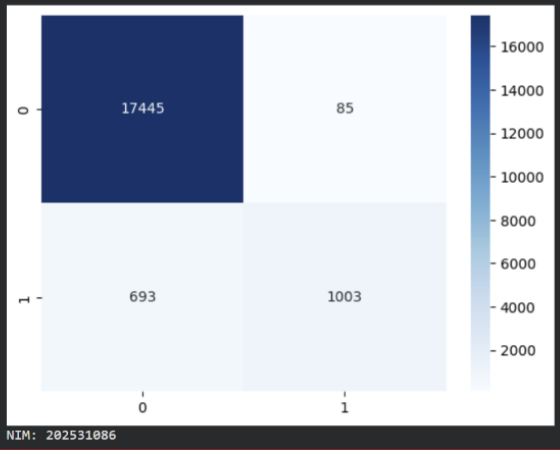
3.5.3 Cell 8: Evaluasi Akhir KNN

```
[8]
✓ 11s
# NIM: 202531086
knn = KNeighborsClassifier(n_neighbors=9).fit(X_train_s, y_train)
pred = knn.predict(X_test_s)
print("Akurasi:", accuracy_score(y_test, pred))
print(classification_report(y_test, pred))
sns.heatmap(confusion_matrix(y_test, pred), annot=True, fmt='d', cmap='Blues'); plt.show()
print("NIM: 202531086")

Akurasi: 0.959533964423177
              precision    recall  f1-score   support

           0       0.96      1.00      0.98     17530
           1       0.92      0.59      0.72      1696

    accuracy                           0.96     19226
   macro avg       0.94      0.79      0.85     19226
weighted avg       0.96      0.96      0.96     19226



NIM: 202531086
```

Gambar 3.7 Cell 8: laporan klasifikasi dan confusion matrix

Model KNN dengan k = 9 dilatih ulang, dipakai memprediksi data uji, lalu dievaluasi memakai accuracy_score, classification_report, dan confusion_matrix yang divisualisasikan dalam bentuk heatmap. Akurasi yang diperoleh adalah 0,9595 atau sekitar 95,95 persen.

Fenomena ini konsisten dengan teori tentang data tidak seimbang (He & Garcia, 2009). Pada KNN dengan k = 9, sebuah data diprediksi positif hanya jika sedikitnya lima dari sembilan tetangganya positif. Karena kelas positif hanya sekitar 9 persen dari data, banyak pasien diabetes yang tetangganya justru didominasi kelas negatif, terutama pada pasien dengan nilai fitur yang mirip dengan non-penderita. Dalam konteks skrining kesehatan, 693 kasus yang terlewat merupakan kelemahan serius, sehingga recall kelas 1 lebih layak dijadikan acuan mutu dibanding akurasi.

3.6 Implementasi Regresi Linear

3.6.1 Cell 9: Pelatihan dan Evaluasi Regresi Linear



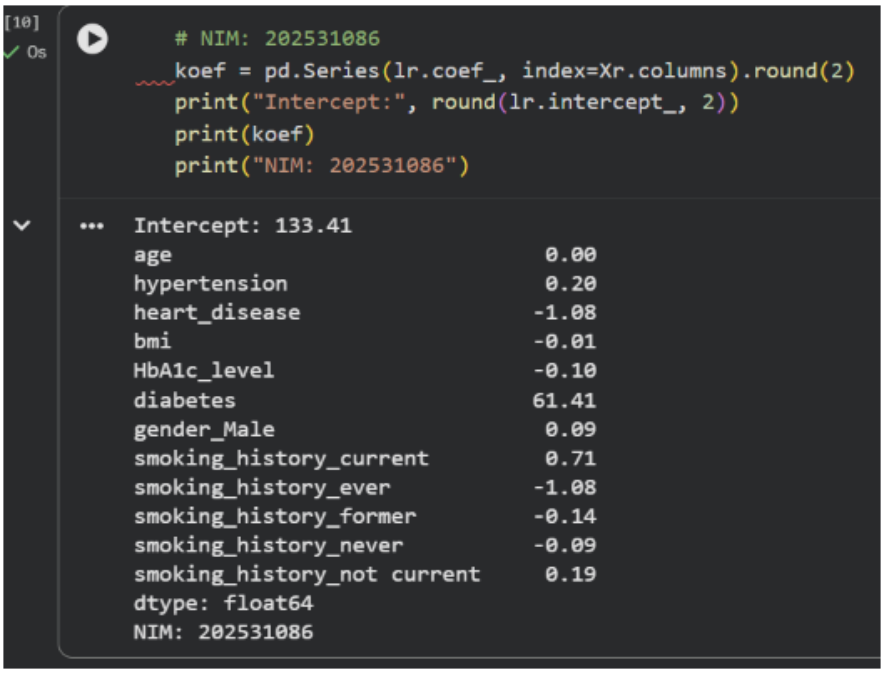
Gambar 3.8 Cell 9: metrik regresi dan diagram sebar prediksi terhadap nilai aktual

Pada cell ini target diganti menjadi blood_glucose_level (yr) dan seluruh kolom lainnya, termasuk diabetes, menjadi fitur (Xr). Data dibagi 80:20 dengan random_state=42 tanpa stratifikasi karena targetnya numerik. Standarisasi tidak dilakukan karena OLS tidak terpengaruh

oleh skala fitur. LinearRegression().fit melatih model, predict menghasilkan prediksi untuk data uji, dan tiga metrik dihitung bersama diagram sebar prediksi terhadap nilai aktual.

Hasilnya adalah MAE sebesar 30,70, RMSE sebesar 37,01, dan R^2 sebesar 0,1806. MAE berarti prediksi rata-rata meleset sekitar 31 satuan dari kadar glukosa sebenarnya, sedangkan RMSE yang lebih besar menunjukkan adanya beberapa kesalahan yang besar. RMSE 37,01 hanya sedikit lebih baik daripada simpangan baku target (sekitar 40,7), yaitu galat yang akan diperoleh jika model selalu menebak rata-rata. Nilai R^2 0,1806 menyatakan bahwa model hanya menjelaskan sekitar 18 persen variasi kadar glukosa darah.

3.6.2 Cell 10: Koefisien Model



Gambar 3.9 Cell 10 beserta output

Koefisien kolom diabetes sebesar 61,41 jauh melampaui koefisien fitur lain yang semuanya berada di sekitar nol (misalnya age 0,00 dan bmi -0,01). Artinya model pada dasarnya hanya membedakan dua kelompok: pasien non-diabetes diprediksi bernilai sekitar 133 dan pasien diabetes sekitar 194 (133,41 + 61,41), sesuai dengan rata-rata glukosa kedua kelompok pada data latih. Itulah sebab dua pita pada diagram sebar; variasi kecil di dalam tiap pita berasal dari koefisien fitur lain yang sangat kecil.

BAB IV
PENUTUP

4.1 Kesimpulan

Pertama, hasil EDA menunjukkan bahwa dataset berisi 100.000 baris dan sembilan kolom tanpa nilai hilang, tetapi memiliki 3.854 baris duplikat, 18 baris gender Other, dua fitur kategorikal, dan kelas target yang timpang dengan proporsi diabetes sebesar 8,5 persen. Fitur dengan korelasi terkuat terhadap diabetes adalah kadar glukosa darah (r = 0,420) dan HbA1c (r = 0,401).

Kedua, preprocessing yang dilakukan meliputi penghapusan duplikat dan gender Other, one-hot encoding dengan drop_first untuk gender dan smoking_history, pembagian data latih dan uji 80:20 dengan stratifikasi, serta standarisasi yang hanya di-fit pada data latih untuk KNN. Data akhir berukuran 96.128 baris dengan 12 fitur.

Ketiga, KNN dengan k = 9 menghasilkan akurasi 0,9595 pada data uji dengan selisih akurasi latih dan uji hanya 0,0049. Namun recall kelas diabetes hanya 0,59 (F1-score 0,72) akibat ketidakseimbangan kelas, sehingga sekitar 41 persen pasien diabetes pada data uji tidak terdeteksi.

Keempat, Regresi Linear untuk target blood_glucose_level menghasilkan MAE 30,70, RMSE 37,01, dan R^2 0,1806. Model hanya membedakan pasien diabetes dan non-diabetes melalui koefisien kolom diabetes, sehingga Regresi Linear kurang cocok untuk memprediksi kadar glukosa pada dataset ini karena hubungan antar variabel tidak linear dan nilai glukosa bersifat diskret.

4.2 Saran

Untuk pengembangan berikutnya, penulis menyarankan beberapa hal. Pertama, atasi ketidakseimbangan kelas dengan SMOTE atau pembobotan, dan pilih nilai k melalui validasi silang berstrata agar data uji tidak ikut dipakai dalam pemilihan parameter. Kedua, jadikan recall, F1-score, dan ROC-AUC sebagai acuan utama, bukan hanya akurasi. Ketiga, bila target numerik tetap ingin diprediksi, coba algoritma non-linear seperti pohon keputusan atau random forest, dan pertimbangkan apakah kolom diabetes pantas dipakai sebagai fitur untuk memprediksi glukosa. Terakhir, konfirmasikan kepada dosen bahwa target blood_glucose_level sesuai dengan maksud soal untuk Regresi Linear.

DAFTAR PUSTAKA

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research, 16*, 321-357.

Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory, 13*(1), 21-27.

García, S., Luengo, J., & Herrera, F. (2015). *Data preprocessing in data mining*. Springer.

Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer.

He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering, 21*(9), 1263-1284.

International Diabetes Federation. (2025). *IDF Diabetes Atlas* (11th ed.). https://diabetesatlas.org

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning with applications in R* (2nd ed.). Springer.

Mitchell, T. M. (1997). *Machine learning*. McGraw-Hill.

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to linear regression analysis* (5th ed.). Wiley.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825-2830.

Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management, 45*(4), 427-437.

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.